

Soutenance de thèse

Conception d'un système mémoire pour traitement de données creuses

Thèse soutenue par

Valentin ISAAC--CHASSANDE

le 11 mai 2026

Université Grenoble Alpes, CEA List, TiMA

PLAN

1. Les matrices creuses

2. Accélérateurs dédiées et Directions

3. Cache de réduction

4. SpDCCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCCache via un modèle analytique

6. Evaluations et Performances de SpDCCache

7. Conclusion

PLAN

1. Les matrices creuses

2. Accélérateurs dédiés et Directions

3. Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

LES MATRICES CREUSES

Applications : Physiques numériques, Intelligence artificielle, Analyse de graphes...

→ Matrice creuse

- **Larges** (nombre d'éléments non-nuls jusqu'à $\sim 10^9$)
- **Creuses** (densité jusqu'à $\sim 10^{-7}$)

→ **Compressées en mémoire** : Formats creux

• Diverses

- ▶ En tailles et densités
- ▶ En structures



[1] Zhiyao Li, Jiaxiang Li, Taijie Chen, Dimin Niu, Hongzhong Zheng, Yuan Xie, and Mingyu Gao. 2023. Spada : Accelerating Sparse Matrix Multiplication with Adaptive Dataflow. ASPLOS 2023. Association for Computing Machinery, 747–761.

LES FORMATS CREUX

Formats creux [2] [3] → pour éviter de stocker les zéros

- Beaucoup de formats spécifiques à des structures de matrices
- CSR et CSC → les plus simples et plus utilisées

CSR (Compressed Sparse Row)

CSC (Compressed Sparse Column)

[2] Reginald P. Tewarson. 1973. Sparse matrices. Vol. 69. Academic press New York, State University of New York, Stony Brook, NY.
[3] Yousef Saad. 2003. Iterative Methods for Sparse Linear Systems (second ed.). Society for Industrial and Applied Mathematics.

ÉCHANGER UN PROBLÈME POUR UN AUTRE

Formats creux :

→ **Empreinte mémoire réduite** de $\mathcal{O}(n^2)$ à $\mathcal{O}(n)$ → une nécessité

→ **Utilisation de métadonnées** → génèrent des transactions mémoires vers des adresses non-consécutives



Indirections

- **Accès indirects** depuis/vers la hiérarchie mémoire
- Du point de vue d'un système mémoire naïf : **accès « aléatoires »**

LES NOYAUX DE CACLUL (KERNELS)

Où apparaissent les indirections ?

Les matrices creuses sont utilisées dans de **nombreux kernels** :

- $1\mathcal{D}$ Multiplication **matrice** creuse-**vecteur** : SpMV
 - $2\mathcal{D}$ Multiplication **matrice-matrice** : SpMSpM, SpGEMM, SpMM
 - $n\mathcal{D}$ Les **tenseurs** en général
- } **Kernels de base**
utilisés dans la majorité
des applications

Chaque kernel peut être implémenté suivant **plusieurs algorithmes** :

- **Inner-Product** (IP) ($\geq 1\mathcal{D}$)
 - **Outer-Product** (OP) ($\geq 1\mathcal{D}$)
 - **Gustavson** (ou Row-wise) ($\geq 2\mathcal{D}$)
- } **Algorithmes de base**
Des algorithmes plus complexes peuvent être vues
comme des combinaisons de ces trois là.
- Méthodes de tiling → ~ algorithmes customisés / pré-traitement ($\geq 1\mathcal{D}$)

KERNELS CREUX – INNER-PRODUCT SpMV

Exemple de **SpMV** (multiplication matrice creuse-vecteur) : $A \times b = c$, avec A de taille (M, N) .

- $\forall (i, j) \in \llbracket 0, M-1 \rrbracket \times \llbracket 0, N-1 \rrbracket$, $c_i = c_i + A_{i,j} \times b_j$
- A est stockée avec un format creux comme CSR ou CSC
- Des **accès indirectes** apparaissent, sur les entrées ou la sortie, en fonction de l'algorithme :
 - ▶ **Inner-Product (IP)** :

$c_0 += A_{0,0} \times b_0$ (0)
 $c_0 += A_{0,0} \times b_0$ (0)
 $c_0 += A_{0,0} \times b_0$ (0)
 $c_0 += A_{0,0} \times b_0$ (0)
 $c_0 += A_{0,0} \times b_0$ (0)
 $c_0 += A_{0,0} \times b_0$ (0)
 $c_0 += A_{0,0} \times b_0$ (0)
 $c_0 += A_{0,0} \times b_0$ (0)
 $c_0 += A_{0,0} \times b_0$ (0)



$c_0 += VAL_0 \times b_{IDX_0}$ ①
 $c_0 += VAL_0 \times b_{IDX_0}$ ①
 $c_0 += VAL_0 \times b_{IDX_0}$ ①
 $c_0 += VAL_0 \times b_{IDX_0}$ ①

→ Avec le **SpMV** en **Inner-Product**, les accès « **aléatoires** » se produisent sur le **vecteur d'entrée b** , au moment de calculer la **somme partielle** $A_{i,j} \times b_j$.

KERNELS CREUX – OUTER-PRODUCT SPMV

idem pour OP (faire court à l'oral)

KERNELS CREUX – MM

(très rapide sur cette slide)

Matrice-matrice -> SpMM, SpMSpM, SpGEMM

Aussi IP et OP

Mêmes remarques sur les indirections mais sur matrice entière au lieu de vecteur

En plus, Gustavson -> intermédiaire, scatter et gather mais sur les lignes des matrices B et C

LA HIÉRARCHIE MÉMOIRE

Pourquoi les accès « aléatoires » sont un problème ?

Avec une matrice dense → localités spatiale et temporelle
Avec une **matrice creuse** → **pas de localité**

Dans une architecture classique

- Les hiérarchies mémoires prennent avantage des accès temporellement et spatialement locaux

Caches → **non-adaptés** aux accès « aléatoires »

- Cache remplie de zéros (lignes de cache remplies à 40% d'éléments non-nuls)
- Nombre de hits bas
- Évincements non-nécessaires → Beaucoup de **transactions mémoires** avec des **temps de réponse élevés**

Simple **préfetcher linéaire** → pas suffisant pour s'occuper du goulot d'étranglement mémoire

RÉSUMÉ

Inner-Product → accès « aléatoires » sur l'entrée (b ou B) → accès = lecture

→ Problème : comment **rassembler** efficacement les données → **gather**

→ **Intersections** des éléments non-nuls de A avec ceux de b ou B (1D ou 2D)

Outer-Product → accès « aléatoires » sur la sortie (c ou C) → accès = lecture + accumulation + écriture

→ Problème : comment **distribuer** efficacement les données → **scatter**

→ **Réductions** des sommes partielles non-nuls dans c ou C (1D ou 2D)

Gustavson → accès « aléatoires » sur l'entrée et la sortie (B et C)

→ Les deux problèmes de **gather** et **scatter** à la fois

→ **Intersections** avec les **lignes de B** seulement (1D)

→ **Réductions** « aléatoires » dans les **lignes de C** seulement (1D)

PROBLÉMATIQUE

(fusionner avec slide précédente ?)

Dans le contexte du calcul matriciel, comment adresser efficacement les problématiques d'intersections (gather) et/ou de réductions (scatter) lorsque les données subissent des accès « aléatoires » ?

PLAN

1. Les matrices creuses

2. Accélérateurs dédiés et Directions

3. Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

ACCÉLÉRATEURS MATÉRIELS DÉDIÉS

<flèche temporelle :>

1973 : Approches logicielles sur CPUs [2] / 2005 : Approches logicielles pour GPUs [4] / 2018 - aujourd'hui : **Accélérateurs matériels dédiés au calcul creux**

Plusieurs caractéristiques

- **Kernel** : Matrice-Matrice Matrice-Vecteur Générique
- **Algorithme** : Inner-Product Outer-Product Gustavson Méthodes de tiling
- **Problèmes adressés** : Gather (Intersections) Scatter (Réductions)
- **Type d'accélérateur** : Complet Assisté par processeur
- Pour les accélérateurs assistés par processeur, **position dans la hiérarchie mémoire** :
Proche processeur Proche caches Esquive caches Proche mémoire principale

ACCÉLÉRATEURS MATÉRIELS DÉDIÉS

<ajouter couleur slide précédente sur table / ajout nb total>

Nom	Année	Autonomie		Position dans la hiérarchie mémoire			Algorithme(s) le(s) plus adapté(s)			Support matériel pour		Kernels creux adressés	
		Complet	Assisté	Proc.	Caches	Mém.	IP	OP	Gust	Gather	Scatter	MV	MM
Coup	2015		✓		✓			✓			✓	✓	~
EIE	2016	✓						✓		✓	✓	✓	
OuterSPACE	2018	✓						✓		✓	✓	✓	✓
GraphR	2018	✓						✓		✓	✓	✓	
SDE	2019	✓					✓		~	✓	~	✓	~
ExTensor	2019	✓					✓	~		✓	~	~	✓
PHI	2019		✓		✓			✓	~		✓	✓	~
SPiDRE	2019		✓			✓	✓			✓		✓	~
ITS	2019	✓						✓		✓	✓	✓	
SPU	2019	✓					✓	✓		✓	✓	✓	
Tensaurus	2020	✓					~	~		✓	✓	✓	✓
MatRaptor	2020	✓							✓	✓	✓		✓
SpArch	2020	✓						✓		✓	✓		✓

→ **Diversité** des choix de design, toutes les caractéristiques sont couvertes

Exploration des algorithmes **IP et OP**

Exploration de l'algorithme de **Gustavson**

Combinaisons d'algorithmes

DESIGN SPACE

<diagramme complet - simplifié?>

Montrer liens assist = générique, ... -> différences entre complets et assistés (avantages et inconvénients)

QUELLE EST LA MEILLEURE SOLUTION ?

Les accélérateurs matériels dédiés

- **Répondent efficacement à la problématique du calcul creux** ✓
- Les méthodes et choix de design sont **diverses**
 - Une comparaison de performance exhaustive est difficile
- **Une comparaison juste est difficile à réaliser**
 - À la place, on aimerait une **vision claire du design space** <FIXME> slide précédente
 - On compare seulement les performances des algorithmes pour les accélérateurs complets <FIXME>

UN BESOIN DE SUPPORT POUR LES RÉDUCTIONS

(fusionner avec slide précédente ?)

Parmi accélérateurs complets, majoritairement MM -> Gust puis OP

-> analyse théorique ok

- - > ** Besoin de support pour les réductions! **

Remarque sur les variations des perfs selon les structures des matrices

- - > ** Besoin de considérer les structures! **

DIRECTION

Hypothèses :

- Noyau de calcul : **SpMV** (multiplication matrice creuse-vecteur)
- Algorithme : **OP** (*Outer-Product*)
- Problème : Scatter → **Réductions « aléatoires »**
- Architecture de **type générique**, faible coût en surface
→ Au niveau des **caches de données**

Approche :

- **SpDCache** : Cache de données spécialisé qui adresse les réductions « aléatoires »

Objectif 1 : Mitiger l'irrégularité des réductions en analysant le comportement des caches de données

Objectif 2 : Comprendre le rôle des structures des matrices dans les performances

PLAN

1. Les matrices creuses

2. Accélérateurs dédiées et Directions

3. Cache de réduction

- Cache générique
- Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

CONTEXTE

Noyau de calcul : SpMV (multiplication
matrice creuse-vecteur)

Algorithme : OP (*Outer-Product*)

Avec OP SpMV, les accès « aléatoires » se
produisent sur le vecteur de sortie et sont des
réductions

→ Réductions « aléatoires »

Une réduction sur un vecteur v :

$v_{\text{indice}} += \text{valeur}$

- Une lecture en mémoire de v_{indice}
- Une accumulation pour mettre à jour v_{indice} avec
 valeur
- Une écriture en mémoire de v_{indice} mis à jour

Cette opération est noté RED :

$\text{RED}(\text{indice}, \text{valeur})$

SpMV : $A \times b = c$

Avec A une matrice creuse de taille (M, N) ,
 b et c des vecteurs denses de taille N et M

OP (*Outer-Product*)

```
for  $n \in [0, N - 1]$ 
  for  $m \in [0, M - 1]$ 
     $c_m += A_{m,n} \times b_n$ 
  end
end
```

→ Accès séquentiels sur les entrées A et b

→ Accès « aléatoire » sur le vecteur de sortie c

< raccourcir ! >

< ajouter une phrase pour expliquer le but de
cette section >

CACHE GÉNÉRIQUE

Granularité : ligne de cache (64 octets)

Transactions mémoires : lecture et écriture de ligne de 64 octets

Réduction : $c_{indice} += valeur$

Cas de hit :

- Lecture du cache ✓
- Accumulation dans le processeur
- Ecriture dans le cache ✓

Cas de miss :

- Lecture en mémoire et mise à jour du cache ✗
- Accumulation dans le processeur
- Ecriture dans le cache ✓

Cas de miss avec évincement :

- Ecriture en mémoire de la donnée évincée ✗
- Lecture en mémoire et mise à jour du cache ✗
- Accumulation dans le processeur
- Ecriture dans le cache ✓



<schéma d'une réduction dans un cache générique>

CACHE DE RÉDUCTION

Cache de réduction : cache générique avec quelques modifications

- Supporte des instructions de réduction RED
- Possède un accumulateur : accumulation dans le cache



<Figure comme SpDCache (voir ASAP) ou on montre ce qu'il y a en plus par rapport à un cache générique (?)>

CACHE DE RÉDUCTION



<schéma d'une réduction dans un cache générique>



<schéma d'une réduction dans un cache de réduction>

Comparaison du nombre d'instruction / le processeur n'attend pas les REDs

GC 0 1 2

RedC 0 0 2

Evincement : le processeur n'attend pas de réponse

PLAN

1. Les matrices creuses

2. Accélérateurs dédiés et Directions

3. Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

LES MATRICES BANDÉES

Présenter les matrices bandées

CONCEPT DE SPDCACHE

Par rapport à un cache générique :

- Ajout du **mode réduction**
- Ajout d'une **FPU** (unité de calcul flottant)
- Partage de la mémoire cache en **trois régions** :

- **DRC** pour la région dense, en-bande
 - Vecteur c uniquement
 - Réductions uniquement
 - Granularité d'une ligne de cache
 - Associatif à ensemble
- **SRT** pour la région creuse, hors-bande
 - Vecteur c uniquement
 - Réductions uniquement
 - Granularité d'un élément
 - Complètement associatif
- **GRC**
 - Lectures génériques de A et b

<ajouter figure avec les modifs apportés à un cache générique>

ARCHITECTURE DE SPDcACHE

Du texte pour expliquer comment passent les données dans le cache

A, b dans GRC

Dans processeur : En ou hors bande de A? /

Axb -> c

RED (c Axb reg) vers L1

Selon reg, DRC ou SRT

Evincements vers mémoire, soit ligne wise soit RMW

► Utilise des transactions atomique RMW
(lecture-accumulation-écriture)

<figure de spdcache + direction des transactions (globales) de A,b à c>

ARCHITECTURE DE SPDcACHE

Transactions RED -> "envoyées et oubliées"

<figure avec animations du fonctionnement de
spdcache>

Hit / Miss

- **Pas** de transaction mémoire
- Insertion ou accumulation dans le cache

Miss avec évincement dans le DRC

- 2 transactions mémoires
- Accumulation dans le cache

Miss avec évincement dans la SRT

- 1 transaction mémoire
- "envoyé et oublié"
- Accumulation en mémoire principale

(note sur les duplications)

PLAN

1. Les matrices creuses

2. Accélérateurs dédiées et Directions

3. Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

MULTIPLICATION MATRICE-VECTEUR DANS UN CACHE GÉNÉRIQUE

Matrice quelconque :

- Évincements répétés dans le cache
- Le cache n'est pas utile ✖

Petite matrice, bande horizontale :

- Tiens dans le cache, pas d'évincement
- Le cache est utile ✔
- Cas peu intéressants ✖

Matrice bandée :

- Évincements répétés dans le cache
- Le cache n'est pas utile ✖
- Structure très courante ✔

Matrice parfaitement bandée :

- Nombre d'évincements limité
- Le cache est utile ✔
- Structure peu courante ✖



list

TRAFFIC MÉMOIRE THÉORIQUE AVEC DES MATRICES BANDÉE

C

Traffic mémoire du vecteur de sortie
versus

densité en dehors de la bande,
pour différentes tailles de cache

- Densité dans la bande fixe (10^{-2})
 -
- Réduction de deux ordres de grandeur
- SI Matrice parfaitement bandée
 - ET Largeur de bande suffisamment petite par rapport à la taille du cache

<relation>



(graph avec courbes qui apparaissent au bon moment)

CONCLUSION

On sélectionne une bande diagonale de la matrice, qu'on traite avec un cache set-associatif

- <relation>

QUE FAIRE DU RESTE, HORS DE LA BANDE ?

Granularité : Éléments isolés

- Incompatible avec les lignes de cache

→ Pas de ligne de cache :

64o (8 mots) → 8o (1 mot)

Absence de structure claire

- Nombre de *hits* bas

→ Pour augmenter la quantité de *hits*
dans un espace de cache modeste :

Cache complètement associatif

Transactions mémoires inadaptées

- Lectures et écritures sur 64o (8 mots)

→ Transactions mémoires "par éléments"

RMW atomique sur 8o (1 mot)



(graph avec courbes qui apparaissent au bon moment)

CONCLUSION

On traite les éléments hors-bande de la matrice avec un cache « par élément », complètement associatif, avec des transactions mémoires « par élément » (RMW)

CONCLUSION

Conclusion un peu globale : SpDCache permet d'adresser le problème des réductions aléatoires en utilisant intelligemment l'espace mémoire disponible ("bloquer" la région la plus dense / gérer les éléments isolés)

PLAN

1. Les matrices creuses

2. Accélérateurs dédiés et Directions

3. Cache de réduction

4. SpDCCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCCache via un modèle analytique

6. Evaluations et Performances de SpDCCache

7. Conclusion

ENVIRONNEMENT

CVA6 + SpDCache + RAM

TRAFFIC MÉMOIRE

Set de 48 à 62 matrices

Toutes structures

Config 25/50/25

Perfs avec écart type (brut et ×)

Conclu : réduction significative du trafic mémoire

On note deux groupes (transition vers speedup)

ACCÉLÉRATION

1 coeur CVA6, basse perf -> on est dans une zone entre compute et memory bound

Permet de clasifier les marices selon nouveau critere dcd

Explique les deux groupes d'accélération

Conclu : Comme attendu, reduction du trafic permet accélération sur matrice memory bound /
classification des matrices selon densité des lignes de cache

PLAN

1. Les matrices creuses

2. Accélérateurs dédiées et Directions

3. Cache de réduction

4. SpDCCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCCache via un modèle analytique

6. Evaluations et Performances de SpDCCache

7. Conclusion

CONCLUSION

Revenir sur la problématique
Et sur les Q1 et Q2

Thanks!

contact

backup slides :

Exploration des paramètres (Python)

BaCSC

Toutes les perfs

Perf Python

Algo Gust SpMSpM

Analyses théoriques des algos de SpMSpM / SpMV

1 ou 2 tableaux comparant les algos de façon détaillé (voir manuscrit)

Ajouter exemple d'accélérateurs du SoA ? (Gamma et PHI)

Quelques slides sur le RTL

Les comparaisons de modèles

Les autres graphes de l'analyse théorique