

Soutenance de thèse

Conception d'un système mémoire pour traitement de données creuses

Thèse soutenue par

Valentin ISAAC--CHASSANDE

le 11 mai 2026

Université Grenoble Alpes, CEA List, TiMA

PLAN

1. Les matrices creuses

2. Accélérateurs dédiées et Directions

3. Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

PLAN

1. Les matrices creuses

2. Accélérateurs dédiés et Directions

3. Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

LES MATRICES CREUSES

Applications : Physiques numériques, Intelligence artificielle, Analyse de graphes...



→ Matrice creuse

- **Larges** (nombre d'éléments non-nuls jusqu'à $\sim 10^9$)
- **Creuses** (densité jusqu'à $\sim 10^{-7}$)

→ Compressées en mémoire : Formats creux

• Diverses

- En tailles et densités
- En structures



[1] Zhiyao Li, Jiaxiang Li, Taijie Chen, Dimin Niu, Hongzhong Zheng, Yuan Xie, and Mingyu Gao. 2023. Spada : Accelerating Sparse Matrix Multiplication with Adaptive Dataflow. ASPLOS 2023. Association for Computing Machinery, 747–761.

LES FORMATS CREUX

Formats creux [2] [3] → pour éviter de stocker les zéros

- Beaucoup de formats spécifiques à des structures de matrices
- CSR et CSC → les plus simples et plus utilisées

CSR (Compressed Sparse Row)

CSC (Compressed Sparse Column)

[2] Reginald P. Tewarson. 1973. Sparse matrices. Vol. 69. Academic press New York, State University of New York, Stony Brook, NY.
[3] Yousef Saad. 2003. Iterative Methods for Sparse Linear Systems (second ed.). Society for Industrial and Applied Mathematics.

ÉCHANGER UN PROBLÈME POUR UN AUTRE

Formats creux :

- **Empreinte mémoire réduite** de $\mathcal{O}(n^2)$ à $\mathcal{O}(n)$ → une nécessité
- **Utilisation de métadonnées** → génèrent des transactions mémoires vers des adresses non-consécutives

Indirections

- **Accès indirects** depuis/vers la hiérarchie mémoire
- Du point de vue d'un système mémoire naïf : **accès « aléatoires »**

LA HIÉRARCHIE MÉMOIRE

Pourquoi les accès « aléatoires » sont un problème ?

Noyau de calcul avec une matrice dense → localités spatiale et temporelle
Noyau de calcul avec une **matrice creuse** → **pas de localité**

Dans une architecture classique

- Les hiérarchies mémoires prennent avantage des accès temporellement et spatialement locaux

Caches → **non-adaptés** aux accès « aléatoires »

- Cache remplie de zéros (lignes de cache remplies à 40% d'éléments non-nuls)
- Nombre de hits bas
- Évincements non-nécessaires → Beaucoup de **transactions mémoires** avec des **temps de réponse élevés**

Simple **préfetcher linéaire** → pas suffisant pour s'occuper du goulot d'étranglement mémoire

LES NOYAUX DE CACLUL (KERNELS)

Les matrices creuses sont utilisées dans de **nombreux kernels** :

- $1\mathcal{D}$ Multiplication **matrice** creuse-**vecteur** : SpMV
 - $2\mathcal{D}$ Multiplication **matrice-matrice** : SpMSpM, SpGEMM, SpMM
 - $n\mathcal{D}$ Les **tenseurs** en général
- } **Kernels de base**
utilisés dans la majorité des applications

Chaque kernel peut être implémenté suivant **plusieurs algorithmes** :

- **Inner-Product** (IP) ($\geq 1\mathcal{D}$)
 - **Outer-Product** (OP) ($\geq 1\mathcal{D}$)
 - **Gustavson** (ou Row-wise) ($\geq 2\mathcal{D}$)
- } **Algorithmes de base**
Des algorithmes plus complexes peuvent être vues comme des combinaisons de ces trois là.
- Méthodes de tiling → ~ algorithmes customisés / pré-traitement ($\geq 1\mathcal{D}$)

LES INDIRECTIONS DANS LES KERNELS CREUX

Où apparaissent les indirections ?

SpMV : $A \times b = c$, avec A de taille (M, N)

- Dense :
- Creux en Inner-Product (CSR) :
- Creux en Outer-Product (CSC) :

$$c_i += A_{i,j} \times b_j \quad \text{Indirection} \quad (\forall (i,j) \in [0, M-1] \times [0, N-1])$$

$$c_i += VAL_p \times b_{IDX_p} \quad (\forall p \in [PTR_i, PTR_{i+1} - 1])$$

$$c_{IDX_p} += VAL_p \times b_j \quad (\forall p \in [PTR_j, PTR_{j+1} - 1])$$

↑
Indirection

SpMM, SpMSpM : $A \times B = C$

- Inner-Product : Indirections sur toute la matrice d'entrée B
- Outer-Product : Indirections sur toute la matrice de sortie C
- Gustavson : Indirections sur les lignes de B et dans les lignes de C
 - Intermédiaire entre Inner-Product et Outer-Product

RÉSUMÉ

Inner-Product → accès « aléatoires » sur l'entrée (b ou B) → accès = lecture

→ Problème : comment **rassembler** efficacement les données → **gather**

→ **Intersections** des éléments non-nuls de A avec ceux de b ou B (1D ou 2D)

Outer-Product → accès « aléatoires » sur la sortie (c ou C) → accès = lecture + accumulation + écriture

→ Problème : comment **distribuer** efficacement les données → **scatter**

→ **Réductions** des sommes partielles non-nuls dans c ou C (1D ou 2D)

Gustavson → accès « aléatoires » sur l'entrée et la sortie (B et C)

→ Les deux problèmes de **gather** et **scatter** à la fois

→ **Intersections** avec les **lignes de B** seulement (1D)

→ **Réductions** « aléatoires » dans les **lignes de C** seulement (1D)

Problématique initiale

→ Dans le contexte du calcul matriciel, comment adresser efficacement les problématiques d'intersections (gather) et/ou de réductions (scatter) lorsque les données subissent des accès « aléatoires » ?

PLAN

1. Les matrices creuses

2. Accélérateurs dédiés et Directions

3. Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

ACCÉLÉRATEURS MATÉRIELS DÉDIÉS

<flèche temporelle :>

1973 : Approches logicielles sur CPUs [2] / 2005 : Approches logicielles pour GPUs [4] / 2018 - aujourd'hui : **Accélérateurs matériels dédiés au calcul creux**

Plusieurs caractéristiques

- **Kernel** : Matrice-Matrice Matrice-Vecteur Générique
- **Algorithme** : Inner-Product Outer-Product Gustavson Méthodes de tiling
- **Problèmes adressés** : Gather (Intersections) Scatter (Réductions)
- **Type d'accélérateur** : Complet Assisté par processeur
- Pour les accélérateurs assistés par processeur, **position dans la hiérarchie mémoire** :
Proche processeur Proche caches Esquive caches Proche mémoire principale

ACCÉLÉRATEURS MATÉRIELS DÉDIÉS

Sous-ensemble sur **43 accélérateurs** étudiés entre 2015 et 2025.

Nom	Année	Autonomie		Position dans la hiérarchie mémoire			Algorithme(s) le(s) plus adapté(s)			Support matériel pour		Kernels creux adressés	
		Complet	Assisté	Proc.	Caches	Mém.	IP	OP	Gust	Gather	Scatter	MV	MM
Coup	2015		✓		✓			✓			✓		✓
EIE	2016	✓						✓		✓	✓	✓	✓
OuterSPACE	2018	✓						✓		✓	✓	✓	✓
ExTensor	2019	✓					✓	✓		✓	✓	✓	✓
SPIDRE	2019		✓			✓				✓	✓	✓	✓
ITS	2019	✓						✓		✓	✓	✓	✓
MatRaptor	2020	✓							✓	✓	✓	✓	✓
SpArch	2020	✓						✓		✓	✓	✓	✓
Gamma	2021	✓						✓		✓	✓	✓	✓
SPAGHETTI	2021	✓						✓		✓	✓	✓	✓
InnerSP	2021	✓						✓		✓	✓	✓	✓
Sextans	2022	✓						✓		✓	✓	✓	✓
ASA	2022		✓							✓	✓	✓	✓
Flexagon	2023	✓		✓			✓	✓		✓	✓	✓	✓
MOSCON	2023	✓						✓		✓	✓	✓	✓
GSCSp	2023	✓						✓		✓	✓	✓	✓
GAS	2024	✓				✓		✓		✓	✓	✓	✓
ACES	2024	✓						✓		✓	✓	✓	✓
Sparm	2024	✓					✓	✓		✓	✓	✓	✓
SPADES	2024	✓					✓	✓		✓	✓	✓	✓
Vesper	2024	✓					✓	✓		✓	✓	✓	✓
IOPS	2025	✓					✓	✓		✓	✓	✓	✓
C ³ ache	2025		✓		✓			✓		✓	✓	✓	✓
ScanNow	2025	✓						✓		✓	✓	✓	✓

→ **Diversité** des choix de design, toutes les caractéristiques sont couvertes

Exploration des algorithmes **IP et OP**

Exploration de l'algorithme de **Gustavson**

Combinaisons d'algorithmes

DESIGN SPACE

- **Accélérateur complet**
= spécifique, performance

- Kernel spécifique
- Application spécifique (parfois)
- Mémoires customisées
- Hautes performances
- Surface conséquente

- **Assisté par processeur**
= flexible, faible coût

- Pour tous kernels
- Mémoires existantes
- Intégrable dans divers systèmes
- Intégration peu évidente
- Performances moins élevées
- Faible surface ajoutée

<diagramme simplifié>

QUELLE EST LA MEILLEURE SOLUTION ?

Les accélérateurs matériels dédiés (complets et assistés)

- **Répondent efficacement à la problématique du calcul creux** ✓

- Les méthodes et choix de design sont **diverses**

→ Une comparaison de performance exhaustive est difficile

→ **Une comparaison juste est difficile à réaliser**

→ À la place, on a une **vision claire du design space**

→ On compare seulement les performances des algorithmes pour les accélérateurs complets

UN BESOIN DE SUPPORT POUR LES RÉDUCTIONS

Parmi les accélérateurs complets (majoritairement pour les kernels Matrice-Matrice)

→ **N°1 : Gustavson** présente les meilleurs performances et avantages

→ **N°2 : Outer-Product**, N°1 pour le kernel SpMV

Vérifiable avec une **analyse gros grain** :

→ Nombre de données transférées en mémoire principale

→ Pour chaque algorithme, en fonction d'une taille de mémoire locale

→ **Besoin de support pour les réductions « aléatoires »**

En général, pour tous les accélérateurs :

→ Grandes **variations de performances** selon les matrices et leurs **structures**

→ **Besoin de considérer les structures des matrices**

DIRECTION DE CETTE THÈSE

Hypothèses :

- Noyau de calcul : **SpMV** (multiplication matrice creuse-vecteur)
- Algorithme : **OP** (Outer-Product)
- Problème : Scatter → **Réductions « aléatoires »**
- Architecture de **type générique**, faible coût en surface
→ Au niveau des **caches de données**

Approche :

- **SpDCache** : Cache de données spécialisé qui adresse les réductions « aléatoires »

Objectif 1 : Mitiger l'irrégularité des réductions en analysant le comportement des caches de données

Objectif 2 : Comprendre le rôle des structures des matrices dans les performances

PLAN

1. Les matrices creuses

2. Accélérateurs dédiées et Directions

3. Cache de réduction

- Cache générique
- Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache


7. Conclusion

SPMV EN OUTER-PRODUCT

Exemple de **SpMV** : $A \times b = c$, avec A de taille (M, N) .

- $\forall (i, j) \in \llbracket 0, M-1 \rrbracket \times \llbracket 0, N-1 \rrbracket$, $c_i = c_i + A_{i,j} \times b_j$
- A est stockée au format creux CSC (VAL , IDX , PTR)
- **Outer-Product (OP)** : des **accès indirectes** apparaissent sur la sortie

Indirections


$$\begin{aligned} c_{IDX_0} &+= VAL_0 \times b_0 & \textcircled{1} \\ c_{IDX_1} &+= VAL_1 \times b_1 & \textcircled{2} \\ c_{IDX_2} &+= VAL_2 \times b_2 & \textcircled{3} \\ c_{IDX_3} &+= VAL_3 \times b_2 & \textcircled{4} \end{aligned}$$

→ Avec le **SpMV** en **Outer-Product**, **les accès « aléatoires » se produisent sur le vecteur de sortie c** , au moment d'accumuler la **somme partielle** $A_{i,j} \times b_j$ avec c_i .

→ **Réductions « aléatoires »**

→ Lectures séquentiels des matrice et vecteur d'entrées A et b

RÉDUCTIONS

Qu'est-ce qu'une réduction ?

Une réduction sur le vecteur c : $c_{indice} += valeur$

- Une **lecture** en mémoire de c_{indice}
- Une **accumulation** pour mettre à jour c_{indice} avec $valeur$
- Une **écriture** en mémoire de c_{indice} mis à jour

Cette opération est noté **RED** : $RED(indice, valeur)$

Cache générique : pas de support particulier pour les opérations de réduction

→ **Cache de réduction** (ex. : [5] [6])

- Supporte une **nouvelle instruction RED** : $RED(adresse, valeur)$
- L'opération de réduction est **traitée dans le cache**
 - Possède une **unité de calcul**

[5] A. Mukkara, N. Beckmann, and D. Sanchez. 2019. PHI : Architectural Support for Synchronization- and Bandwidth-Efficient Commutative Scatter Updates. In Proceedings of the 52nd Annual IEEE/ACM International Symposium on Microarchitecture (MICRO-52). Association for Computing Machinery, New York, NY, USA, 1009–1022.

[6] S. Srikanth, A. Jain, T. M. Conte, E. P. DeBenedictis, and J. Cook. 2021. SortCache : Intelligent Cache Management for Accelerating Sparse Data Workloads. ACM Trans. Archit. Code Optim. 18, 4, Article 56 (sep 2021), 24 pages.

CACHE GÉNÉRIQUE

Comment se comporte une réduction dans un cache générique ?

• Cas de hit :

- Lecture du cache ✓
- Accumulation dans le processeur
- Ecriture dans le cache ✓

• Cas de miss :

- Lecture en mémoire et mise à jour du cache ✗
- Accumulation dans le processeur
- Ecriture dans le cache ✓

• Cas de miss avec évincement :

- Ecriture en mémoire de la donnée évincée ✗
- Lecture en mémoire et mise à jour du cache ✗
- Accumulation dans le processeur
- Ecriture dans le cache ✓



<schéma d'une réduction dans un cache générique>

CACHE DE RÉDUCTION



- **Nombre intrinsèque de transactions mémoires**
 - Cache générique : $0 + 1 + 2 = 3$ ✗
 - Cache de réduction : $0 + 0 + 2 = 2$ ✓
- Les réductions sont « **envoyées et oubliées** » :
 - Le processeur **n'attend pas de réponse**, même à l'évincement

SpDCache : cache de réduction

→ **Réductions** ✓ « **aléatoires** » ✗

PLAN

1. Les matrices creuses

2. Accélérateurs dédiées et Directions

3. Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

LES MATRICES BANDÉES

SpDCache : tirer partie des **structures** des matrices

- Une structure de matrice fréquente : la **structure bandée**
 - Une **région dense** autour de la diagonale : **en-bande**
 - Une **région creuse** ailleurs : **hors-bande**



→ **Densités**

- En-bande : $\sim 10^{-3}$ (de 10^{-8} à 10^{-2})
- Hors-bande : $\sim 10^{-4}$ (de 0 à 10^{-2})
- Structure naturelle dans les systèmes linéaires
 - Corrélation élevée des composantes proches
- Techniques de diagonalisation des matrices
- **Parfaitement bandée** : hors-bande à zéro

CONCEPT DE SPDCACHE

Par rapport à un cache générique :

- Ajout du **mode réduction**
- Ajout d'une **FPU** (unité de calcul flottant)
- Partage de la mémoire cache en **trois régions** :

- **DRC** pour la région dense, en-bande
 - Vecteur c uniquement
 - Réductions uniquement
 - Granularité d'une ligne de cache
 - Associatif à ensemble
- **SRT** pour la région creuse, hors-bande
 - Vecteur c uniquement
 - Réductions uniquement
 - Granularité d'un élément
 - Complètement associatif
- **GRC**
 - Lectures génériques de A et b

<ajouter figure avec les modifs apportés à un cache générique>

ARCHITECTURE DE SpDCACHE

→ SpDCache

- Lecture de A et $b \rightarrow$ GRC
- Transactions mémoires classiques
 - ▶ Taille d'une ligne de cache

→ Processeur

- Somme partielle : $valeur = A_{i,j} \times b_j$
- Région de la matrice : $region$ de $A_{i,j}$
- $RED(adresse\ de\ c_i, valeur, region)$

→ SpDCache

- Insertion ou accumulation
 - ▶ $region$ en-bande $\rightarrow$ DRC
 - ▶ $region$ hors-bande $\rightarrow$ SRT

<figure de spdcache + direction des transactions (globales) de A, b à c >

A, b dans GRC

Dans processeur : En ou hors bande de A ? /
 $Axb \rightarrow c$

RED ($c\ Axb\ reg$) vers L1

Selon reg, DRC ou SRT

Evincements vers mémoire, soit ligne wise soit
RMW

ARCHITECTURE DE SPDcACHE

Transactions RED → « **envoyées et oubliées** »

<figure avec animations du fonctionnement de
spdcache>

Hit / Miss

- **0** transaction mémoire
- Insertion ou accumulation dans le cache

Transferts entre DRC et SRT

→ **pas de duplication**

Miss avec évincement dans le DRC

- **2** transactions mémoires (lignes)
- Accumulation dans le cache

Miss avec évincement dans la SRT

- **1** transaction mémoire (**élément**)
- « **Envoyé et oublié** »
- Accumulation en mémoire principale
 - ▶ RMW (lecture-accumulation-écriture)
 - ▶ AMOs AXI-4

PLAN

1. Les matrices creuses

2. Accélérateurs dédiées et Directions

3. Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

MULTIPLICATION MATRICE-VECTEUR DANS UN CACHE GÉNÉRIQUE

Matrice quelconque :

- Évincements répétés dans le cache

✗ Le cache n'est pas utile

Petite matrice, bande horizontale :

- Tiens dans le cache, pas d'évincement

✓ Le cache est utile

✗ Cas peu intéressants

Matrice bandée :

- Évincements répétés dans le cache

✗ Le cache n'est pas utile

✓ Structure très courante

Matrice parfaitement bandée :

- Nombre d'évincements limité

✓ Le cache est utile

✗ Structure peu courante



list

TRAFFIC MÉMOIRE THÉORIQUE AVEC DES MATRICES BANDÉE

Traffic mémoire (vecteur de sortie)

versus

densité hors-bande, pour différentes tailles de cache

- Normalisé par nombre d'éléments non-nuls
- Densité en-bande fixe (10^{-2})
- [?] $s_C = S \times W \times l$

→ Réduction de deux ordres de grandeur

- SI Matrice parfaitement bandée
- ET Largeur de bande (w_B)

suffisamment petite par rapport à la
taille du cache (s_C)

$$s_C \geq w_B + \text{taille ligne de cache} - 1$$

→ DRC efficace : sélection de la bande diagonale de la matrice, dont la largeur dépend de la taille du DRC



(graph avec courbes qui apparaissent au bon moment)

QUE FAIRE DU RESTE, HORS DE LA BANDE ?

Granularité : **Éléments isolés**

- Incompatible avec les lignes de cache

→ Pas de ligne de cache :

- 64o (8 mots) → 8o (1 mot)

Absence de structure claire

- Nombre de *hits* bas
- #### → Pour augmenter la quantité de *hits* dans un espace de cache modeste :
- Cache complètement associatif

Transactions mémoires inadaptées

- Lectures et écritures sur 64o (8 mots)
- #### → Transactions mémoires « par éléments »
- RMW sur 8o (1 mot)

→ **SRT efficace : éléments isolés (hors-bande) de la matrice traités « par élément », dans la SRT et au niveau des transactions mémoires**



(graph avec courbes qui apparaissent au bon moment)

CONCLUSION

SpDCache : cache de réduction séparé en plusieurs régions

→ **Réductions** ✓ « **aléatoires** » ✓

On utilise la structure à gros grain des matrices

On se base sur le comportement des caches pour proposer la séparation en plusieurs régions

La solution fonctionne pour toute structure, mais est plus adapté au bandé

Est-ce que la combinaison des deux régions réduit les perfs ?

PLAN

1. Les matrices creuses

2. Accélérateurs dédiées et Directions

3. Cache de réduction

4. SpDCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCache via un modèle analytique

6. Evaluations et Performances de SpDCache

7. Conclusion

ENVIRONNEMENT

CVA6 + SpDCache + RAM

TRAFFIC MÉMOIRE

Set de 48 à 62 matrices

Toutes structures

Config 25/50/25

Perfs avec écart type (brut et ×)

Conclu : réduction significative du trafic mémoire

On note deux groupes (transition vers speedup)

ACCÉLÉRATION

1 coeur CVA6, basse perf -> on est dans une zone entre compute et memory bound

Permet de clasifier les marices selon nouveau critere dcd

Explique les deux groupes d'accélération

Conclu : Comme attendu, reduction du trafic permet accélération sur matrice memory bound /
classification des matrices selon densité des lignes de cache

PLAN

1. Les matrices creuses

2. Accélérateurs dédiées et Directions

3. Cache de réduction

4. SpDCCache : Fonctionnement et Architecture Matérielle

5. Validation de SpDCCache via un modèle analytique

6. Evaluations et Performances de SpDCCache

7. Conclusion

CONCLUSION

Revenir sur la problématique
Et sur les Q1 et Q2

slide publi et autres ?

Thanks!

contact

backup slides :

Exploration des paramètres (Python)

BaCSC

Toutes les perfs

Perf Python

Algo Gust SpMSpM

Analyses théoriques des algos de SpMSpM / SpMV

1 ou 2 tableaux comparant les algos de façon détaillé (voir manuscrit)

Ajouter exemple d'accélérateurs du SoA ? (Gamma et PHI)

Quelques slides sur le RTL

Les comparaisons de modèles

Les autres graphes de l'analyse théorique

Algo IP et OP en creux